Universidad Técnica Nacional

Proyecto # 1 Minería de datos 3C2026

La empresa Invacom Inc S.A. tiene la necesidad de llevar a cabo la implementación de un data warehouse. Con este propósito, se invita a los miembros del equipo a participar en este desafío. Se organizarán **grupos de máximo 4 personas** para llevar a cabo una investigación teórico-práctica centrada en el proceso de ETL (Extracción, Transformación y Carga) y Data Warehouse. **Para el desarrollo práctico de este ejercicio, se le proporcionará a cada grupo una base de datos específica que servirá como fuente de información.**

Cada grupo deberá explorar y comprender los fundamentos teóricos detrás de estos procesos, así como llevar a cabo su aplicación práctica. Este ejercicio no solo permitirá a los estudiantes adquirir conocimientos sólidos en el ámbito de data warehousing, sino que también les brindará la oportunidad de enfrentarse a un escenario relevante para el entorno laboral actual.

Control de Versiones y Avances Semanales Para simular un entorno de desarrollo profesional, es obligatorio el uso de **Git** como sistema de control de versiones.

- Los equipos deberán alojar sus scripts (Python, SQL), proyectos de ETL y documentación en un repositorio remoto (ej. GitHub, GitLab o Bitbucket).
- Se debe evidenciar el trabajo colaborativo: todos los miembros del grupo deben tener "commits" registrados.
- Se exigirá la demostración de **avances semanales** a través del repositorio, los cuales serán revisados para garantizar que el desarrollo sea constante y no se realice a última hora.

Metodología de Trabajo Ágil (Scrum)

El desarrollo del proyecto se gestionará utilizando el marco de trabajo ágil Scrum, adaptado al entorno académico. El objetivo es entregar valor incremental al cliente (Invacom Inc S.A.) de manera continua.

- Sprints (Iteraciones): El proyecto se dividirá en Sprints de una semana de duración cada uno. Al final de cada Sprint, el equipo debe tener un incremento funcional o un entregable concreto subido al repositorio.
- Roles: Cada equipo deberá designar un Scrum Master (puede ser rotativo) encargado de liderar las reuniones de planificación y asegurar el cumplimiento de los tiempos. El profesor actuará como Product Owner, resolviendo dudas sobre los requerimientos de Invacom Inc S.A.

- Tablero Kanban: Es obligatorio el uso de una herramienta de gestión visual (como Trello, Jira, Notion o los propios GitHub Projects) para gestionar el *Product Backlog* (las tareas del proyecto) y el *Sprint Backlog* (lo que se hará en la semana).
- Ceremonias adaptadas:
    - *Sprint Planning (Dia de la semana):* El equipo decide qué tareas del enunciado abordarán esa semana.
    - *Daily Standup (Asíncrono vía chat/WhatsApp):* Breve actualización de qué hizo cada uno, qué hará hoy y qué bloqueos tiene.
    - *Sprint Review (Revisión semanal):* Se evidencia el avance a través de los *commits* en Git.

Tareas del Enunciado del Ejercicio

1. **Definir Requisitos del Negocio y Objetivos:** Establecer el propósito general del proyecto.
2. **Entender las necesidades del usuario:** Reunir información de los usuarios finales sobre qué tipo de información necesitan y cómo la utilizarán.
3. **Definir los objetivos del DW:** Establecer metas claras y medibles que el DW debe cumplir para satisfacer las necesidades del negocio.
4. **Identificar Fuentes de Datos:** Analizar la base de datos proporcionada e identificar las tablas, campos y estructuras que serán utilizadas para alimentar el DW.
5. **Evaluar Calidad de Datos:** Analizar la calidad de los datos en la base de datos fuente, identificar problemas (nulos, duplicados, formatos inconsistentes) y establecer estrategias para su limpieza y transformación.
6. **Diseñar el Esquema del Data Warehouse (Modelado Dimensional):** Utilizar técnicas como el modelo estrella o copo de nieve para diseñar las dimensiones y las tablas de hechos del DW.
7. **Determinar Dimensiones y Medidas:** Identificar las dimensiones (atributos descriptivos) y las medidas (datos numéricos) que serán almacenadas en el DW.
8. **Establecer Granularidad:** Definir el nivel de detalle de los datos que se almacenarán en el DW.
9. **Diseñar Procesos ETL (Extracción, Transformación y Carga):**
    - **Extracción:** Extraer datos de la base de datos proporcionada.
    - **Transformación:** Limpiar, transformar y enriquecer los datos para que se ajusten al modelo dimensional diseñado y sean útiles para el análisis.
    - **Carga:** Cargar los datos transformados en el DW de manera eficiente y segura.
10. **Desarrollar el Data Warehouse:**
    - **Crear la Infraestructura:** Configurar la base de datos que albergará el DW.

- **Desarrollar ETL:** Implementar los procesos ETL diseñados anteriormente. Se deben utilizar ejemplos que demuestren el dominio de las herramientas.
- **Desarrollar Informes y Consultas:** Visualizar los resultados mediante tablas dinámicas en Excel conectadas al DW.

Dinámica de Presentación y Sustentación (Role-Play)

La presentación final del proyecto se realizará de forma **presencial**. Para hacer la sustentación más realista, se aplicará una dinámica de intercambio de roles:

- Mientras un grupo presenta su solución, **otro grupo designado actuará como el "Jurado Evaluador"**.
- Este jurado representará a la junta directiva y a los usuarios clave de la empresa cliente (Invacom Inc S.A.).
- El grupo expositor deberá "vender" su proyecto, defender las decisiones técnicas tomadas (arquitectura, ETL, modelo dimensional) y responder a las preguntas, dudas o cuestionamientos técnicos y de negocio que el grupo jurado les plantee.

Entregables del Proyecto

La solución documental del proyecto debe presentarse en un solo documento, utilizando formato APA 7, el cual debe contemplar las siguientes partes como mínimo:

- Portada
- Introducción
- Enlace al repositorio de Git (con el código y evidencias de avances semanales)
- Enunciado del problema
- Objetivo General
- Objetivos Específicos
- Descripción de la solución
- Diagrama del Modelo Dimensional (Esquema Estrella o Copo de Nieve)
- Conclusión
- Bibliografía

Cada grupo elegirá una de las siguientes herramientas para realizar el ETL.

Herramienta	Paradigma / Enfoque	Curva de Aprendizaje	Licencia / Disponibilidad	Rol en la Carga del Data Warehouse
1. Python (Pandas/Polars + SQLAlchemy)	Código puro (Scripts)	Media / Alta	Open Source (Gratuito)	Extracción flexible, manipulación en memoria y carga directa mediante conexiones nativas a la base del DW.
2. Microsoft SSIS	Visual (Flujos gráficos)	Media	Licencia SQL Server Developer (Gratuita para estudio)	Estándar corporativo clásico; maneja transformaciones en memoria y carga directa a SQL Server.
3. n8n	Visual (Automatización basada en nodos)	Baja / Media	Fair-code (Gratuito instalando con Docker/npm)	Enfoque moderno de flujos. Permite extraer, transformar visualmente o con código (JS/Python) y hacer *upsert* en el DW.
4. Pentaho Data Integration (Kettle)	Visual (Transformaciones basadas en pasos)	Baja / Media	Open Source (Community Edition)	Interfaz drag-and-drop con pasos especializados para poblar dimensiones y tablas de hechos.
5. KNIME Analytics Platform	Visual (Flujos de nodos)	Baja	Open Source (Gratuito)	Enfoque modular y muy didáctico; cada nodo limpia, une o transforma un bloque de datos antes de cargar.
6. Apache NiFi	Visual / Enrutamiento de datos	Media	Open Source (Gratuito)	Maneja ingesta y movimiento continuo de datos; cuenta con procesadores específicos para ejecutar transformaciones.
7. Airbyte	Modern Data Stack (Conectores ELT)	Baja	Open Source (Despliegue local con Docker)	Sincroniza datos fuente hacia el área de staging del DW de forma automatizada mediante conectores prediseñados.
8. dbt (Data Build Tool)	Código (SQL declarativo + Jinja)	Media	Open Source (dbt Core gratuito)	Ejecuta transformaciones *dentro* del motor del DW a través de sentencias SQL, gestionando dependencias.
9. Apache Airflow	Código (DAGs en Python)	Alta	Open Source (Gratuito)	Orquesta y ejecuta pipelines completos conectando fuentes, ejecutando scripts intermedios y cargando al DW.
10. Apache Spark / PySpark	Código distribuido (Big Data)	Alta	Open Source (Gratuito)	Procesa y transforma grandes volúmenes de datos en paralelo para luego persistirlos en tablas del DW.
11. Mage.ai	Código + UI interactiva (Notebooks)	Media	Open Source (Despliegue local con Docker)	Alternativa moderna a Airflow; integra desarrollo interactivo, pruebas y carga al DW en bloques estructurados.

12. Prefect	Código (Python nativo)	Media	Open Source (Capa gratuita en la nube/local)	Permite transformar scripts de Python en flujos ETL resilientes con reintentos automáticos y orquestación.
13. Azure Data Factory (ADF)	Nube híbrida (Visual / Pipelines)	Media	Pago por uso (Créditos de Azure for Students)	Servicio gestionado en la nube que extrae, transforma y carga directamente a Azure Synapse o SQL Database.
14. AWS Glue	Nube Serverless (Basado en Spark)	Media / Alta	Pago por uso (Capa gratuita / AWS Educate)	Descubre esquemas y genera jobs en PySpark para limpiar y cargar datos procesados hacia repositorios analíticos.
15. Alteryx Designer	No-Code / Low-Code	Baja	Comercial (Licencia educativa gratuita para estudiantes)	Plataforma de analítica visual ampliamente extendida para limpiar fuentes y alimentar modelos dimensionales.
16. Google Cloud Dataflow	Código / Serverless (Basado en Apache Beam)	Alta	Pago por uso (Los estudiantes pueden usar la capa gratuita o créditos de GCP)	Ideal para procesar datos complejos. Permite construir pipelines en Java o Python que se ejecutan de forma distribuida. Puede procesar datos por lotes (batch) o en tiempo real (streaming) antes de cargarlos en BigQuery.
17. Google Cloud Data Fusion	Visual / Nube Totalmente Gestionada	Media	Pago por uso (Requiere control cuidadoso de créditos por el costo de clústeres)	Es una interfaz visual de arrastrar y soltar (basada en el proyecto open source CDAP). Permite construir pipelines ETL gráficamente sin escribir código, facilitando enormemente la limpieza, unión y carga de datos hacia BigQuery.

Una vez se han creado los grupos, se deberá presentar al profesor para que se nombre un coordinador el cual tendrá la tarea de centralizar las consultas del proyecto con el profesor, así como de evaluar a los integrantes del grupo, en función del aporte individual al proyecto, asegurando de esta forma, el aporte equitativo de los integrantes del grupo, de manera que la nota total obtenida se le asignara únicamente el porcentaje indicado en la tabla

Por ejemplo, si el grupo obtuvo un 90% en su presentación de proyecto según la rubrica y uno de los integrantes solo aporto el 70% en el proyecto, según la rúbrica, entonces, dicho integrante solo se le asignara como nota 78%, sin excepciones ni reclamos, y así para todos los demás según su aporte.

	Porcentaje de participación								
	Se une a todas las sesiones de trabajo del equipo, cumple, aporta y ayuda con todas las asignaciones, demuestra un alto dominio del tema y trabajo en equipo.	Se une a todas las sesiones de trabajo del equipo, cumple, con sus asignaciones, pero no aporta al resto del equipo más allá de sus propias tareas.	Se une a algunas las sesiones de trabajo del equipo, cumple, con sus asignaciones, pero no aporta al resto del equipo, solo realizar lo que le corresponde.	Falta a muchas de las sesiones de trabajo del equipo, cumple, pero no se comunica a tiempo, aunque realiza la entrega. (desinterés)	Falta a muchas de las sesiones de trabajo del equipo, no termina sus actividades, no entrega a tiempo su avance. Muestra desinterés	Falta a muchas de las sesiones de trabajo del equipo, retrasa a su equipo, no se hace cargo de sus actividades, entregas parciales	Se une a las sesiones de trabajo, pero recarga su trabajo sobre otro integrante. Al no tener dominio del tema., su aporte es poco o entrega tarde	No se une a las sesiones de trabajo, recarga al equipo, aporta muy poco	Ausente o No colabora en nada o recarga al equipo al no dominar los temas.
	100	**90**	**80**	**75**	**70**	**60**	**50**	**25**	**0**
Integrantes									
Jose Miguel Perez Álvarez			X						

El proyecto se debe presentar de forma presencial, sin excepción, la no presentación establece como nota 0 a la nota obtenida final individual del presente proyecto, sin derecho a reclamo pues, aunque haya participado no podrá demostrar dicha participación.

Rúbrica de Evaluación: Proyecto Data Warehouse Invacom Inc S.A.

Criterio de Evaluación	Excelente (100%)	Bueno (80%)	Suficiente (60%)	Insuficiente (0%)	Valor
1. Diseño y Modelado Dimensional	El diagrama del modelo dimensional (Estrella o Copo de Nieve) es impecable. Define correctamente dimensiones, tablas de hechos, medidas y granularidad acorde a los objetivos del negocio.	El modelo dimensional es funcional pero presenta errores menores en las relaciones, o la granularidad no está completamente clara.	El modelo presenta fallos de diseño significativos (ej. mezcla conceptos transaccionales E/R con dimensionales) o faltan atributos clave.	No se presenta un modelo dimensional claro, o no guarda relación con las necesidades del negocio.	**20%**
2. Desarrollo ETL (Herramienta Asignada)	La extracción, limpieza (manejo de nulos, inconsistencias) y carga son robustas. Demuestran un dominio sobresaliente y justificado de la herramienta ETL que se les sorteó.	El proceso ETL funciona y carga los datos, pero las transformaciones de limpieza son básicas o no aprovechan bien las capacidades de la herramienta.	El ETL logra extraer y cargar, pero omite la limpieza de datos o la ejecución presenta errores que deben corregirse manualmente.	El proceso ETL no funciona, no usa la herramienta asignada en el sorteo, o los datos cargados están corruptos.	**35%**

3. Implementación DW y Visualización	La base de datos del DW está correctamente configurada. Las tablas dinámicas en Excel se conectan al DW de forma exitosa y responden a los requerimientos del usuario con claridad.	El DW está configurado y Excel se conecta, pero los informes generados son genéricos y aportan poco valor a los objetivos iniciales.	Hay problemas de conexión entre Excel y el DW, o los datos en las tablas dinámicas muestran inconsistencias (duplicados, mal sumados).	El DW no fue desplegado correctamente o no se presentaron las vistas/tablas dinámicas requeridas.	**10%**
4. Documentación (Formato APA 7)	El documento incluye todas las partes exigidas. La redacción es profesional, sin errores ortográficos, fundamenta bien las decisiones y aplica el formato APA 7 correctamente.	El documento incluye casi todas las partes, pero la justificación teórica es débil, o presenta algunos errores de formato APA/ortografía.	Faltan secciones clave del documento (ej. objetivos, conclusión). La presentación es desordenada y no sigue el formato APA 7.	Documento incompleto, con plagio, o no entregado en las condiciones solicitadas.	**5%**
5. Control de Versiones (Git) y Trabajo Semanal	El repositorio de Git evidencia un trabajo progresivo y constante (commits semanales). Todos los miembros del equipo tienen aportes equitativos y documentados en el historial.	Hay uso de Git, pero los commits están concentrados en pocas fechas o falta la participación activa de uno de los miembros del equipo.	El uso de Git es mínimo (solo para entregar al final) o el trabajo recayó casi exclusivamente en 1 o 2 personas.	No se entregó enlace al repositorio Git, o el repositorio está vacío/sin historial colaborativo.	**5%**
6. Gestión Ágil (Scrum)	Uso de un tablero Kanban actualizado. Se evidencia una clara división de Sprints y planificación semanal.	Usan un tablero, pero la actualización es irregular o los Sprints no están bien delimitados.	El tablero Kanban existe pero solo se llenó al final para cumplir con el requisito.	No hay evidencia de uso de gestión visual de tareas.	**5%**
7. Sustentación (Role-Play) y Defensa	Excelente dominio del tema. Responden de forma técnica y profesional a las preguntas del grupo "jurado". La exposición es clara, segura y vende bien la solución.	La exposición es buena, pero dudan ante las preguntas críticas del jurado o la defensa técnica carece de profundidad.	La presentación es leída, poco dinámica. No logran responder adecuadamente a los cuestionamientos del jurado ni justificar sus decisiones.	No se presentan a la sustentación, no conocen la solución que desarrollaron o la actitud no es profesional.	**20%**

100%